ФІНАЛЬНИЙ ПРОЄКТ DAN.IT - PYTHON

Прогноз схвалення займу

Аналіз даних, модель RandomForest
і Django-застосунок

Дмитро Пацелюк

github.com/patseluk-lang/loan-approval-prediction

ПРО СЕБЕ

Шлях до програмування не прямий

Шахта	Гірничий технікум, армія. Після розпаду СРСР роботи не стало
Школа	Вчитель фізкультури і трудового навчання; Луганський педагогічний університет
Торгівля	Продаж техніки, власний інтернет-магазин
Кухня	Професійна кухня; друга вища освіта: технолог харчового виробництва (університет розвитку людини «Україна»)
Зараз	**DAN.IT: Python і аналіз даних**

ЗАВДАННЯ

Передбачити рішення банку за даними заявки

На вході

11 ознак заявки: доходи, сума і строк займу, кредитна історія, сім'я, освіта, район розташування нерухомого майна

На виході

Рішення «схвалити» або «відмовити» і ймовірність схвалення

Інструменти: pandas | scikit-learn | matplotlib | seaborn | Jupyter | Django | SQLite

ДОСЛІДЖЕННЯ ДАНИХ

Що є в loan_data.csv

381 заявка

71% схвалено

29% відмовлено

Класи нерівні: модель, яка завжди каже «схвалити», вже вгадує 71%. Тому точність (accuracy) тут погана мірка.

Джерело: частина публічного набору Loan Prediction (Dream Housing Finance), 381 із 614 рядків.

Пропуски в даних

Ознака	Пропусків
Credit_History	30 (7,9%)
Self_Employed	21
Loan_Amount_Term	11
Dependents	8
Gender	5

ЩО ВПЛИВАЄ НА РІШЕННЯ БАНКУ

Кредитна історія важить більше за все інше

Історія відповідає вимогам банку



82,3%

Історія не відповідає вимогам



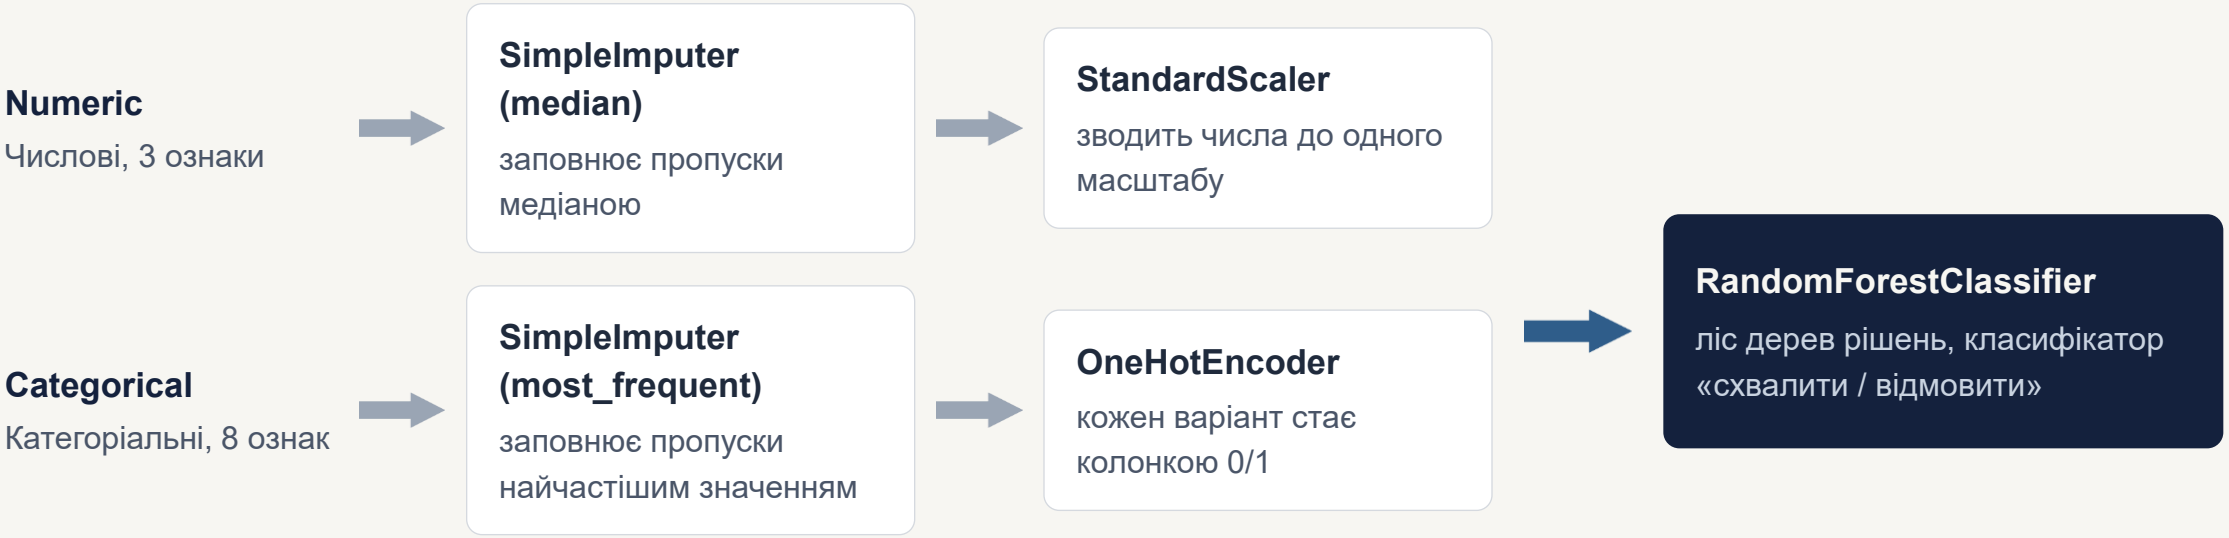
5,3%

Частка схвалених заявок. Кореляція кредитної історії з рішенням 0,62; доходи і сума займу з рішенням майже не пов'язані.

PIPELINE - КОНВЕЄР ОБРОБКИ

Data processing and the model in one object

Обробка даних і модель в одному об'єкті



ColumnTransformer sends each column to its branch

направляє кожну колонку у свою гілку

Missing values are filled inside the Pipeline, from the training part only.

Пропуски заповнюються всередині Pipeline і лише з навчальної частини: тест не «підглядається».

Credit_History and Loan_Amount_Term are encoded as categories.

Кредитна історія і строк записані числами, але це фіксовані варіанти, тому кодую їх як категорії.

ВИБІР І НАЛАШТУВАННЯ МОДЕЛІ

GridSearchCV: 56 combinations × 5 folds

Перебір 56 варіантів параметрів, кожен перевірено на 5 частинах даних

Model - модель	F1 macro
RandomForest, default parameters ліс, параметри за замовчуванням	0,758
LogisticRegression, best логістична регресія, найкращий варіант	0,763
RandomForest, tuned ліс після налаштування: переможець	**0,766**

Best parameters - найкращі параметри

n_estimators = 100
100 дерев у лісі

max_depth = None
глибина дерев не обмежена

min_samples_leaf = 5
щонайменше 5 заявок у листку

class_weight = None
класи без додаткової ваги

Why F1 macro: it scores approvals and rejections separately and takes the average value of the two scores, so a model that approves everyone cannot score high.

Чому F1 macro: ця мірка оцінює схвалення і відмови окремо й бере середнє значення двох оцінок, тому модель, яка всім каже «схвалити», високу оцінку не отримає.

РЕЗУЛЬТАТ НА ТЕСТОВІЙ ВИБІРЦІ (77 ЗАЯВОК)

Модель удвічі краща за «завжди схвалити»

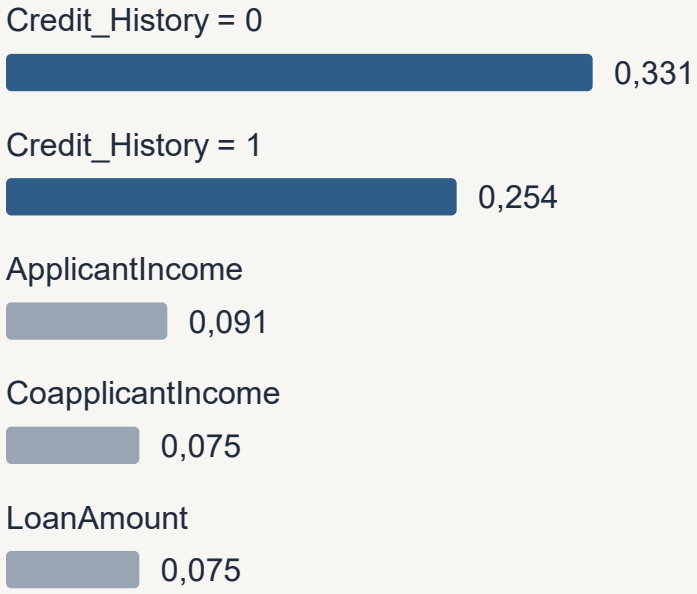
0,788
F1 macro моделі

0,417
«завжди схвалити»

85,7%
accuracy

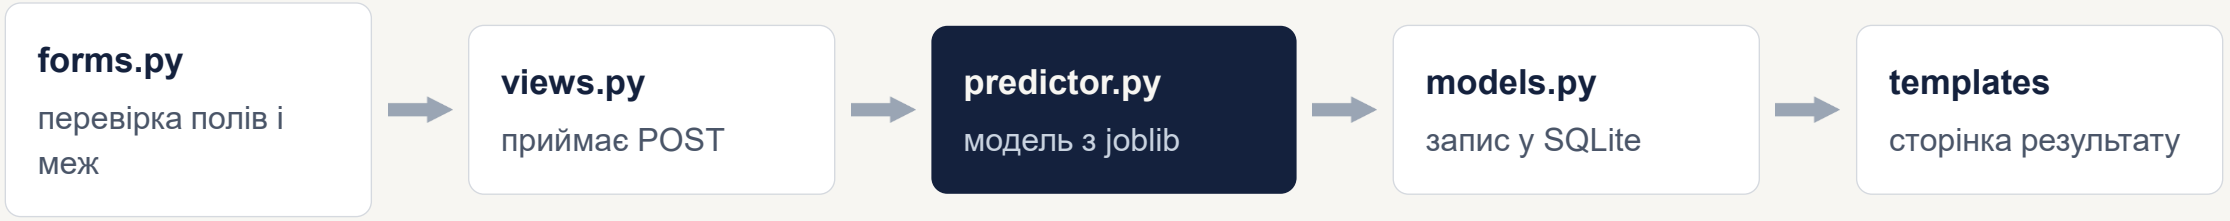
факт \ прогноз	відмова	схвалено
відмова	11	11
схвалено	0	55

Найважливіші ознаки



DJANGO-ЗАСТОСУНОК

Шлях заявки від форми до результату



Нова заявка

Форма з 11 полів, підказки з допустимими межами

Історія заявок

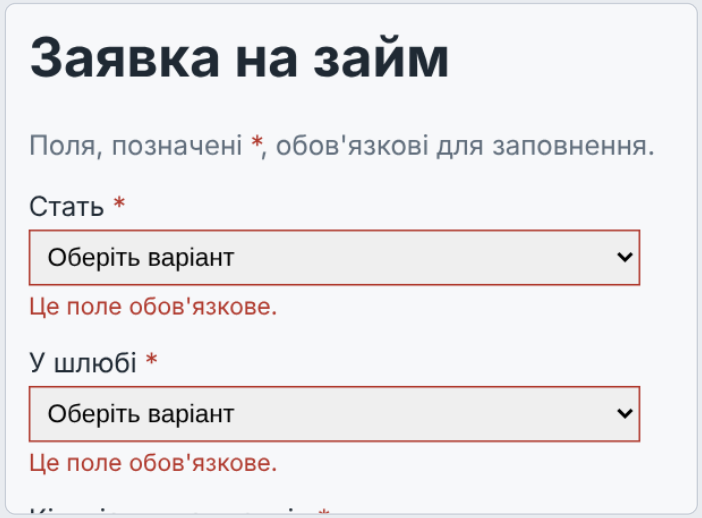
Усі заявки з усіма полями, рішенням і ймовірністю

Про модель

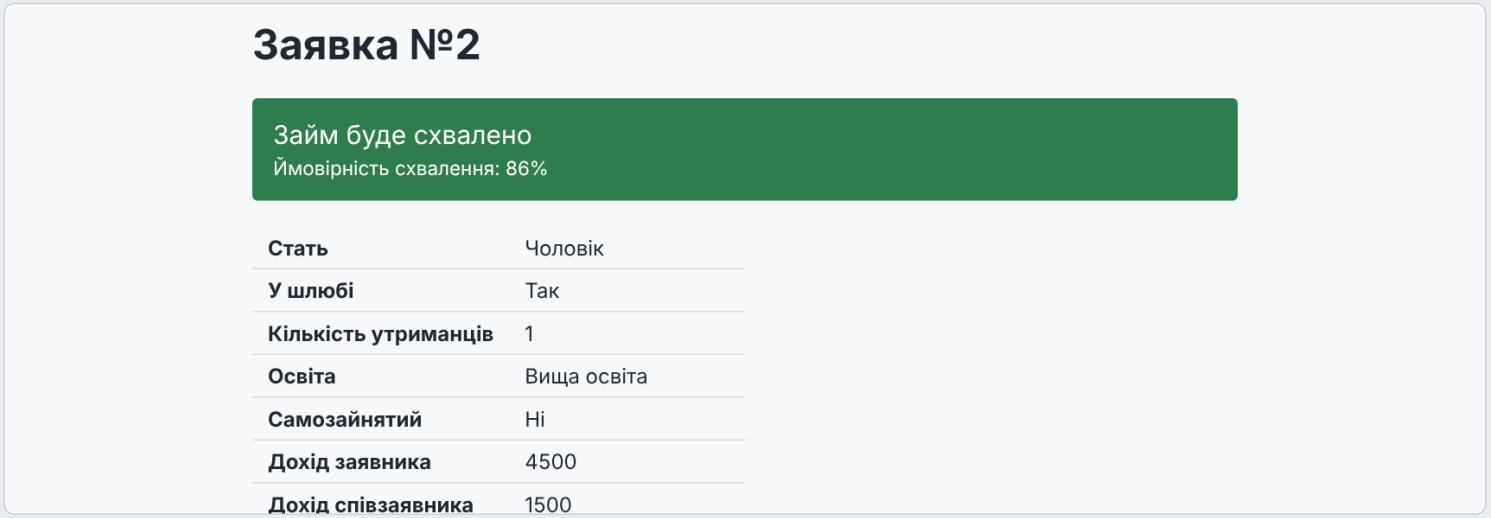
Якість, порівняння моделей, параметри і графіки

Демонстрація

python manage.py runserver → 127.0.0.1:8000



Порожня форма: «Це поле обов'язкове»



Результат: рішення, ймовірність і всі введені дані

№	Дата	Стать	У шлюбі	Утриманці	Освіта	Самозайнятий	Дохід заявника	Дохід співзаявника	Сума займу	Строк	Кредитна історія	Район	Рішення	Ймовірність
2	19.10.2026 16:42	Чоловік	Так	1	Вища освіта	Ні	4500	1500	120000	360 міс.	Відповідає вимогам	Передмістя	схвалено	86%
1	19.10.2026 16:42	Жінка	Ні	0	Вища освіта	Ні	4500	1500	110000	360 міс.	Не відповідає вимогам	Село	відмова	18%

Історія: усі заявки з рішенням моделі

ТЕСТУВАННЯ

19 автоматичних тестів, усі проходять

9

Форма

Порожні поля, від'ємний дохід, текст замість числа, значення поза межами даних і точно на межі

2

Модель

Повертає рішення й імовірність; погана кредитна історія знижує імовірність

8

Сторінки

Заявка зберігається, порожня не зберігається, 404 для неіснуючої, історія, «Про модель»

Запуск: python manage.py test loans
Django сам створює для тестів окрему тимчасову базу даних, проганяє всі 19 перевірок і після цього видаляє її. Заявки в робочій базі db.sqlite3 тести не бачать і не змінюють.
Результат: «Ran 19 tests … OK» - усі перевірки пройдено.

ТРУДНОЩІ І РІШЕННЯ

Що пішло не так і як я це виправив

Одиниці суми

У даних сума займу в тисячах: «150» означає 150 000.

Рішення: у формі сума повністю, у predictor.py ділю на 1000.

Значення поза даними

Займ 500 000 ліс бачить так само, як 150 000: більших у даних не було.

Рішення: валідатори з меж даних і пояснення в повідомленні.

Схвалив банк ≠ поверне борг

Дохід 150 і займ 150 000 з доброю історією: 68% схвалення.

Висновок: модель повторює рішення банку. Тут потрібні інші дані.

ПІДСУМОК

Від CSV-файлу до робочого застосунку

Зроблено

- Дослідження даних і графіки в Jupyter
- Pipeline, перехресна валідація, GridSearchCV
- Django: форма, історія, сторінка про модель
- 19 тестів, README, requirements.txt

Чого навчився

- Спершу розібратися в даних, потім вчити модель
- Мірка якості важить не менше за модель
- Модель не знає більше, ніж є в даних

Дякую за увагу

github.com/patseluk-lang/loan-approval-prediction